

# Aprendizado Profundo Aplicado na Classificação de Microalgas

Iago Corrêa<sup>1</sup>, Paulo Drews-Jr<sup>1</sup>, Márcio S. de Souza<sup>2</sup>, Virgínia Maria Tavano<sup>2</sup>

<sup>1</sup>Centro de Ciências Computacionais– Universidade Federal do Rio Grande (FURG)  
Rio Grande – RS – Brazil

<sup>2</sup>Instituto de Oceanografia– Universidade Federal do Rio Grande (FURG)  
Rio Grande – RS – Brazil

{iago.correa,paulodrews}@furg.br, souzamsd@gmail.com, docvmtg@furg.br

**Abstract.** *Microalgae are unicellular organisms that have physical characteristics such as size, shape and other distinct ultrastructure features. Classifying them manually may require great effort from experts since thousands of microalgae can be found in a small sample of water. Furthermore, the manual classification is a non-trivial operation. We proposed a deep learning technique to solve the problem. The obtained results show an improvement in the classification quality in a end-to-end solution.*

**Resumo.** *Microalgas são organismos unicelulares que apresentam características físicas como tamanho, forma e outras ultra-estruturas específicas de cada grupo. Classificá-las manualmente pode exigir grande esforço de especialista, pois milhares de microalgas podem ser encontradas em uma pequena amostra de água. Além disso, a classificação manual é uma operação não trivial. Neste trabalho, é proposto o uso de técnicas de aprendizado profundo para resolver o problema. Os resultados obtidos mostram melhora na qualidade de classificação em uma solução fim-a-fim.*

## 1. Introdução

Microalgas são um grande grupo composto de protistas eucarióticos fotoautotróficos e cianobactérias procarióticas. Elas representam uma porção significativa de um grupo chamado fitoplâncton. As microalgas têm variados tamanhos, estruturas e formas. A classificação desses organismos é de grande valor nos estudos biológicos e oceanológicos, já que a descrição das espécies de microalgas presentes em um certo momento e lugar é importante para o entendimento a respeito de como a energia é transferida da base da cadeia alimentar para os níveis tróficos mais altos [Cullen et al. 2002]. Baseado neste conhecimento, torna-se possível entender as mudanças nos estoques de peixes e no ciclo do carbono de um dado ambiente. Um trabalho mais recente e com dados decadais, que reuniu pesquisadores de 80 nações, para o mapeamento global da biomassa bentônica e sua relação com a produção/biomassa fitoplanctônica demonstra a importância do estudo desses organismos [Costello et al. 2010].

As microalgas são classificadas em uma grande quantidade de grupos levando em consideração diferentes características, como por exemplo, a composição de pigmentos ou diversidade de ultraestruturas [Singh and Saxena 2015]. Dessa forma, o grupo apresenta

grande variedade morfológica como células arredondadas, ovais cilíndricas, fusiformes, além de projeções como por exemplo espinhos ou cílios. Além disso, a classificação do fitoplâncton também pode se dar pelo tamanho do organismo: picoplâncton (0.2-2  $\mu\text{m}$ ), nanoplâncton (2-20  $\mu\text{m}$ ) e microplâncton (20-200  $\mu\text{m}$ ).

Estudos da composição específica, estrutura de tamanho e biomassa a respeito das comunidades de fitoplâncton vêm sendo desenvolvidos através de métodos clássicos de microscopia ótica [Hamilton et al. 2001]. Através dessa abordagem há uma demanda muito grande de tempo para a realização de uma análise completa, pois é necessário a realização da manipulação manual por parte de um observador em amostras pequenas de água que podem apresentar muitos indivíduos com grande diversidade.

Com o objetivo de se obter informações de forma mais rápida sobre o ambiente aquático, o uso de analisadores de partículas tem sido uma ferramenta importante, pois esses analisadores possibilitam uma obtenção mais rápida e eficiente de informações sobre densidade, composição e morfometria dos organismos fitoplanctônicos. Tal equipamento automatizado é composto por um sistema ótico capaz de distinguir microalgas das demais partículas presentes na amostra e capturar imagens das mesmas, apresentando ainda um software que auxilia na classificação e visualização das células.

O analisador de partículas adotado neste trabalho é o FlowCAM [Jakobsen and Carstensen 2011]. Ele é capaz de obter informação a respeito de micro-organismos presentes em amostras de água, sendo assim uma das contribuições deste trabalho é a criação e a manutenção de um grande banco de dados de microalgas com mais de 29.000 amostras divididas em 24 classes, sendo que 19 dessas classes apresentam um número de organismos suficiente para a realização da classificação supervisionada através do aprendizado profundo.

Uma abordagem para a classificação dos dados extraídos dos analisadores de partículas seria de grande benefício para as pesquisas na área. No entanto, algumas questões importantes estão presentes nesta tarefa; as imagens extraídas do FlowCAM apresentam baixa resolução e neste tipo de dados está presente um desbalanço natural das classes. Além disso, outra questão importante é que os dados utilizados são classificados por diferentes especialistas que geralmente podem adotar diferentes critérios ao longo do tempo. Esses fatos tornam a classificação um problema cuja taxa de acerto atingida por humanos permanece entre 67% e 83% de acordo com [Culverhouse et al. 2003]. Portanto, o presente trabalho propõe a classificação supervisionada através de um modelo de redes neurais convolucionais para superar essas questões.

O modelo proposto neste trabalho consiste em uma rede neural convolucional. No melhor da busca no estado da arte, o presente trabalho é o primeiro a aplicar esse tipo de técnica na classificação de microalgas. As redes neurais convolucionais emergem como estado da arte em termos de acurácia em diferentes tarefas, em especial, apresenta bons resultados na tarefa de classificação de imagens [Szegedy et al. 2015], tornando-o de grande interesse para a classificação das microalgas com base nas imagens extraídas do FlowCAM.

Este artigo é organizado da forma que segue. A Seção 2 discutirá brevemente trabalhos anteriores sobre a classificação de microalgas ou outros organismos de interesse. Na Seção 3 é descrita a metodologia proposta. A Seção 4 traz os resultados obtidos usando

o banco de dados de microalgas proposto. Finalmente, conclusões e trabalhos futuros são apresentados na Seção 5.

## **2. Trabalhos Relacionados**

Na literatura podem ser encontrados diferentes trabalhos que envolvem a tarefa classificatória através de aprendizado profundo, porém nenhum desses consiste exatamente na classificação do mesmo grupo taxonômico de microalgas com base em imagens extraídas de um analisador de partículas. Tal fato se deve a dificuldade de se obter dados classificados suficientes para o aprendizado desse tipo de rede. Além disso, o tamanho reduzido que permite apenas fornecer um pequeno número de características classificáveis faz do problema ainda mais desafiador, limitando as abordagens da literatura.

Diferentes abordagens de classificação baseada na extração prévia de características, por exemplo diâmetro, volume ou razão de aspecto dos organismos, foram avaliadas anteriormente. Alguns trabalhos foram realizados acerca da classificação de zooplâncton, que apesar de serem organismos maiores e com mais características observáveis, compartilham grosseiramente de certos aspectos com o fitoplâncton. [Blaschko et al. 2005], [Xu et al. 2010] e [Sosik and Olson 2007] conseguiram atingir resultados satisfatórios na classificação de plâncton sem utilizar de aprendizado profundo e utilizando características previamente extraídas e selecionadas dos organismos.

No melhor do nosso conhecimento, não há outros trabalhos acerca de métodos de classificação de microalgas baseado em imagens, sem qualquer pré-processamento para análise e seleção de características. [Dai et al. 2016] trabalharam na classificação de zooplâncton baseado em imagens em escala de cinza capturadas pelo sistema ZooScan [Gorsky et al. 2010]. Uma arquitetura de aprendizado profundo associada a um aumento de dados através de amostras artificiais foi proposta para a classificação desse zooplâncton de forma automática. Nenhuma característica foi previamente selecionada ou extraída dos organismos e, assim, o problema foi superado com uma acurácia de 93.7% para 13 classes com imagens de  $256 \times 256$  pixels. Apesar do zooplâncton ser composto de organismos maiores, o problema da baixa resolução de imagens e desbalanço natural das classes também está presente.

Por fim, estudando a classificação dos mesmos organismos [Drews-Jr et al. 2012, Drews-Jr et al. 2013] obtiveram resultados significativos de 92% de acurácia na classificação de microalgas utilizando modelos de misturas Gaussianas junto de aprendizado semi-supervisionado e aprendizado ativo em um banco de apenas quatro classes. Apesar do bom resultado obtido, o trabalho não lidava com o desbalanço, o tamanho do banco de dados utilizado era reduzido e um especialista deveria participar ativamente no processo de classificação. O reduzido tamanho do banco de dados facilita bastante a tarefa, não permitindo uma comparação justa entre o presente trabalho e o trabalho anterior. [Corrêa et al. 2016] buscaram melhores resultados na classificação levando em consideração o desbalanço de classes e atingiram valores altos de acurácia através da utilização de modelos de classificação populares com técnicas de amostragem em um conjunto de 19 classes distintas. Mesmo com valores significativos de acurácia, a abordagem proposta depende intensamente de técnicas de amostragem e do pré-processamento das imagens para obtenção de características visuais.

### 3. Metodologia

Este trabalho apresenta um modelo de rede neural convolucional, do inglês CNN (*Convolutional Neural Network*), como abordagem para classificar de forma eficiente as imagens extraídas das microalgas. Então, inicialmente é apresentada uma introdução de como esses modelos funcionam e do porquê de obterem características significantes das imagens. Então são apresentados a estrutura e processamentos associados ao banco de dados utilizado na classificação.

#### 3.1. Redes Neurais Convolucionais

Para classificar de maneira adequada as imagens das microalgas em baixa qualidade e assim com limitada quantidade de informação, se torna necessário um modelo poderoso capaz de aprender com os dados disponíveis. Nesse sentido, têm-se os modelos de aprendizado profundo. Os modelos têm estado em evidência devido à sua grande capacidade de capturar características visuais da hierarquia dos dados. Esses modelos são aplicados em muitas aplicações [Glorot et al. 2011] [Kalchbrenner et al. 2014] atingindo resultados promissores. Tais resultados são possíveis devido a um alto nível de abstração para dados visuais segundo a utilização de uma estrutura profunda, ou seja, uma quantidade massiva de transformações não lineares e parâmetros que são ajustados.

Dentre os modelos de aprendizado profundo, as CNNs têm se tornado o padrão para a classificação de entradas visuais [Jarrett et al. 2009]. Esses modelos são redes neurais artificiais de alimentação progressiva bio-inspiradas no córtex visual e apresentam uma arquitetura que é composta de camadas que pegam um dado volume de entrada e o transformam em um novo volume de saída.

Essas camadas para a classificação de imagens são geralmente compostas de repetições de conjuntos de convoluções, funções não-lineares e camadas de *pooling*, seguidos de uma camada completamente conectada com a camada de ativação. A camada de *pooling* consiste na realização de um *max pooling*, ou seja, recombinações lineares que diminuem a dimensionalidade, permitindo uma convergência mais rápida devido à seleção de características invariantes e assim aumentando a capacidade de generalização [Nagi et al. 2011]. A função não linear mais utilizada é o ReLU (*Rectified Linear Unit*), pois seu desempenho é melhor na maioria das situações [Krizhevsky et al. 2012].

#### 3.2. Banco de Dados

Os dados são extraídos de amostras de água do Oceano Atlântico Sul (latitude 35°S) utilizando o analisador de partículas FlowCAM. O equipamento fornece 26 características [Jakobsen and Carstensen 2011] e imagens de cada organismo-alvo analisado. Análises anteriores neste tipo de dados utilizaram uma seleção de algumas dessas propriedades para a classificação [Drews-Jr et al. 2012, Drews-Jr et al. 2013, Corrêa et al. 2016], mas para este trabalho nenhuma característica previamente extraída é de interesse, apenas as imagens são utilizadas para o propósito classificatório.

O banco de dados de microalgas é composto por 19 classes com 29.449 imagens. As classes presentes no banco de dados e seus respectivos números de amostras são: Bacillariophycidae-1 (753), Nannoplankton  $< 5\mu\text{m}$  (569), Nannoplankton 5-10 $\mu\text{m}$  (20916), Prorocentrales (211), Spirotrichea (208), Peridinales (189), Gymnodinales (137), Cochlodinium (13), Ellipsoidal Microplankton (171), Spherical Microplankton

(215), Ellipsoidal Nannoplankton 10-20 $\mu$ m (621), Spherical Nannoplankton 10-20 $\mu$ m (3538), Pseudo-nitzschia (703), Bacillariophycidae-2 (261), Chaetocerotales (548), Coscinodiscophyceae (79), Corethron (39), Rhizosoleniales (187), and Naviculales (91). Na Figura 1 é apresentada uma amostra de cada uma das classes.




Figura 1. Uma amostra de cada classe do banco de dados utilizado. As microalgas são adquiridas utilizando o analisador de partículas FlowCAM.

Para o pré-processamento das imagens que compõem o banco de dados o primeiro passo adotado foi o redimensionamento das imagens, pois apresentam ampla variação de tamanho. Como as imagens originais não apresentam alta resolução, o tamanho adotado foi de  $64 \times 64$  pixels com a proporção preservada. Depois disso, é aplicada uma normalização para tornar a média zero e fazer com que o desvio padrão seja unitário. Outras técnicas poderiam ser aplicadas, no entanto o objetivo para este trabalho é atingir bons resultados com o menor pré-processamento possível.

### 3.3. Arquitetura da Rede

Diferentes arquiteturas foram testadas com o objetivo de classificar os organismos da melhor forma possível tendo como referência de validação a acurácia e uma função de erro. Esse erro é associado com a entropia cruzada entre duas distribuições de probabilidades, uma aproximada e outra verdadeira, ou seja, a distribuição de probabilidades prevista e a correta. Dessa forma, foram investigadas redes com diferentes profundidades e números de convoluções, além da influência de maior ou menor regularização.

#### 3.3.1. Treino e validação

Como forma de avaliar apropriadamente os modelos é necessário que seja feita uma divisão do banco de dados em uma parte destinada ao treinamento do modelo e outra parte destinada à validação. Dessa forma, a acurácia obtida pelo modelo é avaliada somente com dados que não estiveram presentes na etapa de treino, evitando que se ocorra o *overfitting*, ou seja, evitando que o modelo se torne específico de mais sendo incapaz de generalizar o aprendizado para amostras novas. Para este trabalho optou-se por utilizar uma divisão de 70% dos dados para a etapa de treino e os 30% restantes para validação.

Além disso, durante a etapa de treino, o banco de dados de treino foi dividido em *mini-batches*, ou seja, divisões bem menores do banco como forma de otimizar o tempo de treinamento, sendo uma vantagem também para o uso de placas de vídeo [Seide et al. 2011]. Não houve qualquer tratamento para tornar esses *mini-batches* mais balanceados, sendo assim, eles mantêm a característica de desbalanço do banco de dados utilizado.

### 3.3.2. Número de camadas e as convoluções

O número de camadas, ou profundidade, pode ser considerado o fator mais importante de um modelo, pois conforme a rede se torna mais complexa este tende a aumentar. Porém, apesar da profundidade estar associada a melhores resultados, é necessário que haja mais dados para acompanhar o aumento e sendo assim não é qualquer modelo que poderá comportar um número grande de camadas [Hinton et al. 2006]. Além disso, o tamanho das convoluções ou *kernel*, bem como o número de convoluções também são importantes para o desempenho do modelo.

Modelos com diversas profundidades e tamanho de convoluções foram testados em busca de um melhor resultado. Devido ao pequeno tamanho e baixa qualidade das imagens dos organismos a serem classificados, convoluções muito grandes não obtiveram resultados relevantes, bem como modelos de profundidade muito grande. Tal fato se deve à quantidade de dados disponíveis em comparação ao número de classes a serem classificadas. Três arquiteturas que apresentaram os resultados mais relevantes se encontram na Tabela 1, a primeira linha identifica o número de camadas e o uso de regularização e nas demais linhas são especificadas a composição das camadas. Os resultados para esses modelos estão presentes na Tabela 2.

Também é importante mencionar que as camadas de ativação utilizam o ReLU como função de ativação. Além disso, foi utilizado o *Max-Pooling* com filtros  $2 \times 2$  nas camadas de *pooling*.

Modelos maiores ou menores não estão dispostos na tabela devido aos baixos resultados e assim, é possível perceber que os dados geram resultados melhores com modelos que apresentam 8 camadas e com convoluções de  $3 \times 3$  ou  $7 \times 7$ . Para o modelo final optou-se para o uso de 8 camadas onde a primeira camada é composta por 16 convoluções de tamanho  $7 \times 7$ , acompanhado de mais 4 camadas de convolução e 3 de redes completamente conectadas conforme mostrado no modelo final presente na figura 2.

## 4. Resultados Experimentais

Após definição de um modelo final conforme discutido na seção anterior, foram avaliadas como métrica de avaliação deste modelo a acurácia e o erro na validação do mesmo. Seus resultados foram de 71.12% de acurácia e um erro 4.67, mostrando assim uma boa chance de acertos mediante o desbalanço dos dados não ter sido diretamente tratado, pouco pré-processamento e nenhuma seleção prévia de características relevantes sobre os organismos classificados.

Tabela 1. Diferentes arquiteturas testadas para a classificação de microalgas.

6 layers	7 layers	8 layers
Input: 64x64 image		
Convolução 16:3x3	Convolução 16:7x7	Convolução 16:3x3
		Convolução 32:3x3
Max-pooling 2x2		
Convolução 64:3x3	Convolução 64:3x3	Convolução 64:3x3
	Convolução 128:3x3	Convolução 128:3x3
Max-pooling 2x2		
Convolução 256:3x3	Convolução 512:3x3	Convolução 256:3x3
Max-pooling 2x2		
FC 4000	FC 6400	FC 6400
FC 512		
Dropout		
FC 19		

Tabela 2. Resultados de classificação em microalgas para diferentes profundidades, convoluções e regularização.

	Acurácia	Erro	
	Validação	Treinamento	Validação
6 layers	0.6334	0.09	3.5183
7 layers	0.6387	0.1	3.5735
8 layers	0.6376	0.1015	3.5907

## 5. Conclusão e Trabalhos Futuros

Este trabalho apresenta o resultado da busca por um modelo de aprendizado profundo com redes neurais convolucionais para realizar a classificação de microalgas.

Além disso, um modelo final é obtido apresentando 8 camadas, sendo 5 convolucionais e 3 camadas completamente conectadas, além de apresentar resultados de 71.12% de acurácia com muito pouco pré-processamento e sem qualquer intervenção de especialista para selecionar características relevantes das microalgas que poderiam facilitar a classificação. Tal abordagem prova sua vantagem uma vez que apresenta uma taxa de acerto esperado similar a de um especialista humano [Culverhouse et al. 2003], é mais independente de pré-processamento de dados do que abordagens do estado da arte para a classificação desses organismos e não apresenta nenhuma abordagem direta ao desbalanceamento dos dados.

Para trabalhos futuros é necessário continuar a expansão do banco de dados atual como forma de obter melhores resultados e de poder realizar a classificação das microalgas em mais classes que não constem ainda nos dados. Pretende-se utilizar *data aug-*




Figura 2. Rede neural convolucional para aprendizado profundo de microalgas.

mentation de modo a aplicar o banco de dados. Além disso, pretende-se aplicar o conceito de redes neurais adversárias como forma de melhorar os resultados com menores quantidades de dados classificados. Finalmente também é de interesse o trabalho para o compartilhamento dos dados tendo como objetivo seu uso ou possíveis colaborações.

## Agradecimentos

Agradecemos ao CNPQ, FAPERGS e FURG por suportar parcialmente o desenvolvimento desta pesquisa. Além disso, também agradecemos a empresa NVIDIA por realizar a doação de uma Titan X Pascal utilizada nos treinos das redes de aprendizado profundo.

## References

- Blaschko, M. B., Holness, G., Mattar, M. A., Lisin, D., Utgoff, P. E., Hanson, A. R., Schultz, H., and Riseman, E. M. (2005). Automatic in situ identification of plankton. In *Application of Computer Vision, 2005. WACV/MOTIONS'05 Volume 1*, volume 1, pages 79–86.
- Corrêa, I., Drews, P., d. Souza, M. S., and Tavano, V. M. (2016). Supervised microalgae classification in imbalanced dataset. In *5th BRACIS*, pages 49–54.
- Costello, M. J., Coll, M., Danovaro, R., Halpin, P., Ojaveer, H., and Miloslavich, P. (2010). A census of marine biodiversity knowledge, resources, and future challenges. *PloS one*, 5(8).
- Cullen, J. J., Franks, P. J., Karl, D. M., and Longhurst, A. (2002). Physical influences on marine ecosystem dynamics. *The sea*, 12:297–336.
- Culverhouse, P., Williams, R., Reguera, B., Herry, V., and González-Gil, S. (2003). Do experts make mistakes? a comparison of human and machine identification of dinoflagellates. *Marine Ecology-progress Series*, 247:17–25.
- Dai, J., Wang, R., Zheng, H., Ji, G., and Qiao, X. (2016). Zooplanktonet: Deep convolutional network for zooplankton classification. In *OCEANS 2016*, pages 1–6.
- Drews-Jr, P., Colares, R., Machado, P., de Faria, M., Detoni, A., and Tavano, V. (2012). Aprendizado ativo e semi-supervisionado na classificacao de microalgas (in portuguese). In *IX ENIA*.
- Drews-Jr, P., Colares, R., Machado, P., de Faria, M., Detoni, A., and Tavano, V. (2013). Microalgae classification using semi-supervised and active learning based on Gaussian mixture models. *Journal of the Brazilian Computer Society*, 19(4):411–422.



- Glorot, X., Bordes, A., and Bengio, Y. (2011). Domain adaptation for large-scale sentiment classification: A deep learning approach. In Getoor, L. and Scheffer, T., editors, *28th ICML*, pages 513–520, New York, NY, USA.
- Gorsky, G., Ohman, M. D., Picheral, M., Gasparini, S., Stemmann, L., Romagnan, J.-B., Cawood, A., Pesant, S., García-Comas, C., and Prejger, F. (2010). Digital zooplankton image analysis using the zooscan integrated system. *Journal of Plankton Research*, 32(3):285.
- Hamilton, P., Proulx, M., and Earle, C. (2001). Enumerating phytoplankton with an upright compound microscope using a modified settling chamber. *Hydrobiologia*, 444(1-3):171–175.
- Hinton, G. E., Osindero, S., and Teh, Y.-W. (2006). A fast learning algorithm for deep belief nets. *Neural Computation*, 18(7):1527–1554.
- Jakobsen, H. and Carstensen, J. (2011). FlowCAM: Sizing cells and understanding the impact of size distribution on biovolume of planktonic community structure. *Aquatic Microbial Ecology*, 65:75–87.
- Jarrett, K., Kavukcuoglu, K., Ranzato, M., and LeCun, Y. (2009). What is the best multi-stage architecture for object recognition? In *12th ICCV*, pages 2146–2153.
- Kalchbrenner, N., Grefenstette, E., and Blunsom, P. (2014). A convolutional neural network for modelling sentences. *CoRR*, abs/1404.2188.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In Pereira, F., Burges, C. J. C., Bottou, L., and Weinberger, K. Q., editors, *Advances in Neural Information Processing Systems 25*, pages 1097–1105.
- Nagi, J., Ducatelle, F., Di Caro, G. A., Cireşan, D., Meier, U., Giusti, A., Nagi, F., Schmidhuber, J., and Gambardella, L. M. (2011). Max-pooling convolutional neural networks for vision-based hand gesture recognition. In *ICSIPA 2011*, pages 342–347.
- Seide, F., Li, G., and Yu, D. (2011). Conversational speech transcription using context-dependent deep neural networks. In *INTERSPEECH 2011*.
- Singh, J. and Saxena, R. C. (2015). An introduction to microalgae. In *Handbook of Marine Microalgae*, pages 11–24.
- Sosik, H. M. and Olson, R. J. (2007). Automated taxonomic classification of phytoplankton sampled with imaging-in-flow cytometry. *Limnology and Oceanography: Methods*, 5(204):e216.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., and Rabinovich, A. (2015). Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1–9.
- Xu, L., Jiang, T., Xie, J., and Zheng, S. (2010). Red tide algae classification using svm-snp and semi-supervised fcm. In *ICETC*, volume 1, pages V1–389.