

Colorização de imagens com Deep Learning

Giovana de Lucca, Elloá B. Guedes

¹Núcleo de Computação
Escola Superior de Tecnologia
Universidade do Estado do Amazonas (UEA)
Manaus – AM – Brasil

gol.eng@uea.edu.br, ebgcosta@uea.edu.br

1. Introdução

1.1. Objetivos

1.2. Justificativa

1.3. Metodologia

1.4. Cronograma

2. Fundamentação Teórica

2.1. Redes Neurais Artificiais

As *Redes Neurais Artificiais* (RNAs) são modelos computacionais inspirados na capacidade de processamento de informações do cérebro humano (ROJAS, 1996). De acordo com esta ideia, possuem unidades de processamento simples, denominadas *neurônios artificiais*, dispostos em camadas interconectadas por ligações associadas a coeficientes numéricos, chamados *pesos* []. As RNAs são capazes de aprenderem padrões complexos a partir dos dados e prever resultados para exemplos não conhecidos, o que demonstra a sua capacidade de generalização [].

Sugerir Haykin

O neurônio artificial é a unidade fundamental na construção de RNAs, tendo sido inspirado no seu análogo biológico. Segundo Rosenblat, existe um conjunto de m entradas, equivalentes aos dendritos de um neurônio biológico, por onde os sinais são introduzidos. Associa-se um peso a cada entrada, representando a relevância referente a uma conexão sináptica. Há também o peso w_0 , um termo de polarização criado com a intenção de estabelecer um limiar de ativação para cada neurônio. Este peso corresponde à entrada *bias*, cujo valor é sempre unitário. Pode-se então definir um vetor de entradas $X = [+1, x_1, x_2, \dots, x_m]$ e um vetor de pesos $W = [w_0, w_1, \dots, w_m]$. As entradas e pesos são combinados por meio de uma função $\phi : \mathbb{R}^{m+1} \rightarrow \mathbb{R}$, que é geralmente a soma ponderada das entradas e pesos, conforme Eq. 1. Este modelo de neurônio encontra-se ilustrado na Figura 1.

citar

$$\phi(X, W) = \sum_{i=0}^m x_i \cdot w_i \quad (1)$$

A função f é chamada de *função de ativação* e fornece a resposta de um neurônio para uma dada entrada. Esta função é monotônica e contínua, podendo comumente ser as funções identidade, sigmóide hiperbólica, tangente hiperbólica, ou a retificada linear (ReLU). Estas funções encontram-se representadas na Figura X.




Figura 1: Falta legenda!



Fazer a figurinha com as quatro funções de ativação.

Neurônios artificiais têm uma capacidade computacional limitada, independentemente da função de ativação escolhida. No entanto, um conjunto de neurônios artificiais conectados na forma de uma rede – *rede neural artificial* – adquirem a capacidade de resolver problemas de elevada complexidade (BRAGA; CARVALHO; LUDERMIR, 2007).

Disposição dos neurônios em camadas



Figura com representação de RNA.

As redes do tipo *Multilayer Perceptron* (MLP) pertencem à arquitetura *feed-forward* com múltiplas camadas divididas em: camada de entrada, uma ou mais camadas ocultas e camada de saída (FACELI et al., 2011).

O algoritmo mais tradicional utilizado no processo de aprendizado (treinamento) das redes MLP é o algoritmo de retropropagação do erro ou *backpropagation* (SOARES; TEIVE, 2015). Durante o treinamento a rede recebe atributos de entrada que são ponderados e combinados entre as camadas por meio dos neurônios por uma função matemática, chamada função de ativação, gerando ao final um valor de saída. Com base no resultado obtido, a próxima etapa consiste na correção dos pesos de cada neurônio que são ajustados proporcionalmente ao seu erro. Esse processo se repete até que seja alcançado um erro mínimo definido e o treinamento seja interrompido (FACELI et al., 2011; SILVA et

al., 2017; AGUNI; KAWAHIRA; CORDEIRO, 2016).

As RNAs têm sido utilizadas para aplicações em diversas áreas como Geografia (SOARES; TEIVE, 2015), Biologia (PADRO et al., 2014), Comunicação (BALIEIRO et al., 2010) e na área Industrial (MARTINS; PREGO; LIMA, 2016). Muitos estudos utilizam as RNAs para classificação de dados, como (SILVA et al., 2017) e (LIMA et al., 2011), ou para previsão de informações como em (PADRO et al., 2014). No processamento de imagens, as RNAs atuam principalmente em conjunto com as técnicas de Aprendizado Profundo ou *Deep Learnig*.

- Ideia
- Conceitos
 - Camadas – camada oculta
 - Neurônios, pesos
 - Funções de ativação
- Aprendizado das RNAs
 - Backpropagation
 - Generalização – aproximadora universal
- Aplicações

2.2. Deep Learning

2.2.1. Redes Neurais Convolucionais

Teste . resto do parágrafo ajdhdkahakjh

3. Trabalhos Relacionados

4. Solução Proposta

4.1. Visão Geral da solução proposta

4.2. Análise Comparativa

5. Considerações Parciais

Referências

AGUNI, C.; KAWAHIRA, A.; CORDEIRO, D. Analise de desempenho e paralelização de algoritmos para redes neurais profundas. 2016.

BALIEIRO, A. et al. Handoff de espectro em redes baseadas em rádio cognitivo utilizando redes neurais artificiais. 2010.

BRAGA, A. de P.; CARVALHO, A. P. de Leon F. de; LUDERMIR, T. B. *Redes Neurais Artificiais: Teoria e Aplicações*. 2. ed. Rio de Janeiro: LTC, 2007.

FACELI, K. et al. *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. [S.l.]: LTC, 2011.

LIMA, P. L. et al. Classificação de qos em conteúdo multimídia para rede vpn utilizando rede neural multilayer perceptron. 2011.

MARTINS, D.; PREGO, T.; LIMA, A. Classificação de severidade de falhas em máquinas rotativas usando *Random Forest* e redes neurais artificiais. 2016.

PADRO, P. et al. Aplicação de redes neurais artificiais no estudo simulado da degradação facultativa de detergentes. 2014.

ROJAS, R. *Neural Networks: A Systematic Introduction*. [S.l.]: Springer, 1996.

SILVA, A. G. et al. Classificação de expressões faciais negativas na língua brasileira de sinais. In: *Anais do IV Encontro Regional de Informática da Região Norte I*. Manaus, Amazonas: ERIN, 2017. p. FALTANDO!

SOARES, D.; TEIVE, R. Previsão de cheias do rio itajaí-açu utilizando redes neurais artificiais. 2015.