

Colorização de imagens com Deep Learning

Giovana de Lucca, Elloá B. Guedes

¹Núcleo de Computação
Escola Superior de Tecnologia
Universidade do Estado do Amazonas (UEA)
Manaus – AM – Brasil

gol.eng@uea.edu.br, ebgcosta@uea.edu.br

1. Introdução

As técnicas de Aprendizado de Máquina (AM) têm sido aplicadas com sucesso em um grande número de problemas reais em diversos domínios. A principal razão disso está relacionada com a capacidade que os computadores conseguem aprender sem a necessidade de serem explicitamente programados para tarefas específicas. A ideia do AM é utilizar algoritmos capazes de aprender através de exemplos, baseando-se apenas em experiências passadas (FACELI et al., 2011; GULLI; PAL, 2017).

A Visão Computacional (VC) é uma área que procura desenvolver métodos capazes de replicar nos computadores as capacidades da visão humana. O reconhecimento de imagens é uma parte integrante do processo de VC e aplica as técnicas de processamento digital de imagens para extrair as características de uma imagem. Antes da era do AM, o procedimento de extração de características de imagens envolvia um grande esforço devido ao processamento e à aplicação de uma variedade de métodos matemáticos. Em algumas situações eram utilizadas análises de um especialista para descobrir as regras necessárias para o reconhecimento e extração das características (FACELI et al., 2011).

Devido ao progresso significativo no campo da VC e da tecnologia de sensores visuais, a VC e o AM desempenharam juntos papéis decisivos no desenvolvimento de uma variedade de aplicações baseadas em processamento digital de imagens (KHAN et al., 2018). Uma das aplicações pioneiras que envolve essas duas áreas se trata do reconhecimento de caracteres manuscritos (*dataset* MNIST). Além disso, a VC e o AM também vêm atuando bastante no campo da Medicina, principalmente na classificação de diagnósticos. Outra aplicação muito difundida é a identificação de conteúdo de imagens (*dataset* CIFAR-10). Neste cenário, um dos projetos emergentes é o ImageNet, o qual disponibiliza um grande banco de imagens projetado para tarefas de VC e propõe anualmente um desafio (*ImageNet Large Scale Visual Recognition Challenge*) que avalia algoritmos para detecção de objetos e classificação de imagens em larga escala.

Nas últimas décadas, com a crescente complexidade dos problemas a serem tratados computacionalmente e do volume de dados gerados por diferentes setores, tornou-se clara a necessidade de ferramentas computacionais mais sofisticadas (FACELI et al., 2011). Embora os algoritmos de AM já existam há bastante tempo, a capacidade de aplicar automaticamente cálculos matemáticos complexos em uma grande escala de dados é um desenvolvimento mais recente. Isso ocorre porque o aumento do poder dos computadores atuais, em termos de velocidade e memória, ajudou as técnicas de AM a evoluir e criar redes neurais com uma grande quantidade de camadas, uma técnica conhecida como *Deep Learning* (DL). As três principais vantagens oferecidas pela DL são a simplicidade

da construção das redes, a escalabilidade, por lidar com um grande volume de dados e a transferência de conhecimento (do inglês *Transfer Learning* - TL), pois um modelo treinado para uma determinada tarefa pode ser aplicado para outras tarefas relacionadas (KHAN et al., 2018).

Considerando este cenário, a proposta do presente trabalho de conclusão de curso visa explorar as arquiteturas canônicas de redes neurais convolucionais utilizando as técnicas de DL e TL aplicadas ao problema de colorização artificial de imagens. Neste problema, uma imagem em escala de cinza (uma imagem histórica, por exemplo) é apresentada a uma rede neural convolucional e, como resposta, se busca uma versão colorida da mesma. Essa colorização deve ser plausível e realista ao ponto de não possuir inconsistência visual quando analisada por pessoas comuns.

Ao longo desta seção serão mostrados os elementos que apresentam este trabalho. A Seção 1.1 contempla os objetivos propostos para o desenvolvimento do projeto. Na Seção 1.2 são apresentadas as justificativas do trabalho em questão. A metodologia adotada é apresentada na Seção 1.3. Por fim, a Seção 1.4 apresenta o cronograma das atividades seguido da Seção 1.5 que dispõe a organização do documento.

1.1. Objetivos

O objetivo geral deste trabalho consiste em propor meios para colorização artificial de imagens utilizando técnicas de *Deep Learning*. Para tanto, fez-se necessário elencar alguns objetivos específicos descritos a seguir:

1. Consolidar uma base de dados composta de imagens coloridas para treinamento das redes;
2. Explorar a utilização de arquiteturas canônicas de redes neurais convolucionais mediante *Transfer Learning* aplicadas ao problema de colorização;
3. Propôr redes neurais convolucionais baseadas nas arquiteturas canônicas elencadas;
4. Treinar as redes propostas utilizando a base de dados consolidada anteriormente;
5. Analisar os resultados obtidos de maneira quantitativa e qualitativa.

1.2. Justificativa

Imagens em escala de cinzas retêm informações que podem ser importantes em diversos aspectos. A colorização de fotos em arquivos antigos pode agregar algum valor aos seus respectivos contextos históricos e artísticos. Algum detalhe de uma imagem em tons de cinza talvez possua outra interpretação se esta mesma imagem estivesse colorizada. Seguindo o mesmo raciocínio, a coloração das imagens de câmeras de segurança com baixa resolução pode influenciar nas interpretações das filmagens.

Na área da saúde, colorizações podem ser ajustadas e modificadas para restaurar algum tipo de perturbação visual. Utilizando as técnicas de colorização com *Deep Learning*, algumas cores podem ser corrigidas para melhorar a visualização de, por exemplo, portadores de daltonismo.

Além disso, a proposta deste trabalho também incentiva a prática de conceitos, técnicas e tecnologias de uma área emergente da computação, contribuindo na formação profissional da aluna concluinte. .

1.3. Metodologia

Para atingir os objetivos propostos no escopo deste trabalho, a condução das atividades seguiu a metodologia apresentada nesta seção, composta dos seguintes passos:

1. Estudo dos conceitos relacionados à *Machine Learning*, *Deep Learning* e as principais arquiteturas de redes neurais convolucionais;
2. Estudo do ferramental tecnológico para elaboração e execução de projetos com *Deep Learning*, incluindo Python, Keras, Sci-kit Learn, Google Cloud Platform, dentre outros;
3. Elaborar uma base de dados representativa de imagens coloridas e em escalas de cinza para fins de aprendizado dos padrões de coloração pelas redes neurais convolucionais;
4. Elencar um conjunto de arquiteturas canônicas das redes neurais convolucionais aplicáveis ao problema em questão;
5. Propor modificações nas redes neurais identificadas no passo anterior mediante *Transfer Learning*;
6. Treinar as redes modificadas com os exemplos da base de dados;
7. Testar as redes e coletar métricas de desempenho;
8. Analisar os resultados obtidos identificando as redes mais adequadas ao cenário considerado;
9. Escrita da proposta do Trabalho de Conclusão de Curso;
10. Defesa da proposta do Trabalho de Conclusão de Curso;
11. Escrita do Trabalho de Conclusão de Curso;
12. Defesa do Trabalho de Conclusão de Curso.

1.4. Cronograma

Uma visão geral do cronograma de atividades a serem desenvolvidas ao longo deste trabalho pode ser vista na Tabela 1. Essas atividades possuem relação com as atividades listadas na Seção 1.3, a qual detalha a metodologia que este trabalho deverá seguir.

1.5. Organização do Documento

Para apresentar a proposta do presente trabalho de conclusão de curso, este documento está organizado como segue. A Seção 2 contempla os fundamentos teóricos necessários para elaboração do projeto, incluindo conceitos de *Machine Learning*, *Deep Learning* e as principais arquiteturas de redes neurais convolucionais. A Seção 3 discorre sobre os trabalhos relacionados. A solução proposta para o tema de colorização de imagens utilizando técnicas de *Deep Learning* é abordada na Seção 4. Por fim, as considerações parciais do trabalho encontram-se na Seção 5.

2. Fundamentação Teórica

Nesta seção serão apresentados os fundamentos teóricos que dão suporte à realização deste trabalho. As redes neurais artificiais, seus principais conceitos, arquiteturas, métodos de aprendizagem e algumas aplicações são percorridas na Seção 2.1. Os conceitos elementares sobre as técnicas de *Machine Learning* conhecidas como *Deep Learning* encontram-se na Seção 2.2. Na Seção 2.3 são descritas as características das redes neurais utilizadas pela técnica de *Deep Learning*, as Redes Neurais Convolucionais. Por fim, as tecnologias utilizadas para a realização deste trabalho são apresentadas na Seção 2.4.

	2018											
	02	03	04	05	06	07	08	09	10	11	12	
Estudo dos conceitos teóricos relacionados à <i>Machine Learning</i>	x	x	x	x								
Estudo do ferramental tecnológico para elaboração do projeto	x	x	x	x								
Consolidação da base de dados			x	x								
Especificação das arquiteturas canônicas de redes neurais convolucionais			x									
Aplicação das técnicas de <i>Transfer Learning</i> nas redes neurais convolucionais identificadas				x								
Treinamento das redes neurais convolucionais com os exemplos da base de dados				x	x	x	x					
Testes das redes e comparação de métricas de desempenho					x	x	x	x				
Análise dos resultados obtidos									x	x	x	
Escrita da proposta do trabalho	x	x	x	x	x							
Defesa da proposta do trabalho					x							
Escrita do trabalho final						x	x	x	x	x	x	
Defesa do trabalho final											x	

Tabela 1: Cronograma de atividades levando em consideração os onze meses (02/2018 a 12/2018) para realização do presente trabalho de conclusão de curso.

2.1. Redes Neurais Artificiais

As *Redes Neurais Artificiais* (RNAs) são modelos computacionais inspirados na capacidade de processamento de informações do cérebro humano (ROJAS, 1996). De acordo com esta ideia, as RNAs possuem unidades de processamento simples, denominadas *neurônios artificiais*, dispostos em camadas interconectadas por ligações associadas a coeficientes numéricos, chamados *pesos* (FACELI et al., 2011). As RNAs são capazes de aprenderem padrões complexos a partir dos dados e prever resultados para exemplos não conhecidos, o que demonstra a sua capacidade de generalização (HAYKIN, 2009).

O neurônio artificial é a unidade fundamental na construção de RNAs, tendo sido inspirado no seu análogo biológico. Segundo Rosenblatt, existe um conjunto de m entradas, equivalentes aos dendritos de um neurônio biológico, por onde os sinais são introduzidos (ROSENBLAT, 1961). Associa-se um peso a cada entrada, representando a relevância referente a uma conexão sináptica. Há também o peso w_0 , um termo de polarização criado com a intenção de estabelecer um limiar de ativação para cada neurônio. Este peso corresponde à entrada *bias*, cujo valor é sempre unitário. Pode-se então definir um vetor de entradas $X = [+1, x_1, x_2, \dots, x_m]$ e um vetor de pesos $W = [w_0, w_1, \dots, w_m]$. As entradas e pesos são combinados por meio de uma função $\phi : \mathbb{R}^{m+1} \rightarrow \mathbb{R}$, que é geralmente a soma ponderada das entradas e pesos, conforme Equação 1. Este modelo de neurônio encontra-se ilustrado na Figura 1 (LIMA, 2016).

$$\phi(X, W) = \sum_{i=0}^m x_i \cdot w_i. \quad (1)$$






Figura 1: Neurônio artificial: a combinação linear das entradas x ponderadas pelos pesos w é transformada pela função de ativação f na saída y .


A função f é chamada de *função de ativação* e fornece a resposta de um neurônio para uma dada entrada. Esta função precisa ser monotônica e contínua, podendo comumente ser as funções identidade, sigmóide, tangente hiperbólica, ou a retificada linear (ReLU) (DELICATO; PIRES; SILVEIRA, 2017). Estas funções encontram-se representadas na Figura 2.




(a) Função identidade.



(b) Função sigmóide.



(c) Função tangente hiperbólica.



(d) Função retificada linear.

Figura 2: Exemplos de diferentes funções de ativação.

Neurônios artificiais individuais têm uma capacidade computacional limitada, independentemente da função de ativação escolhida, pois resolvem apenas problemas linearmente separáveis. No entanto, um conjunto de neurônios artificiais conectados na forma de uma rede – *rede neural artificial* – adquirem a capacidade de resolver problemas de

elevada complexidade (BRAGA; CARVALHO; LUDERMIR, 2007). A alternativa mais utilizada para resolver estes problemas é distribuir os neurônios em uma ou mais camadas conhecidas como camadas ocultas (FACELI et al., 2011). Segundo Cybenko, uma rede com uma camada oculta pode implementar qualquer função contínua e uma rede com duas camadas ocultas permite a aproximação de qualquer função (CYBENKO, 1989).

As RNAs do tipo Perceptron Multicamadas (MLP, do inglês *Multilayer Perceptron*) apresentam uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Uma das principais características de uma rede MLP é o seu alto grau de conectividade entre os neurônios, cuja intensidade está associada aos pesos da rede.

Cada neurônio em uma rede MLP atua ponderando as entradas recebidas dos neurônios de uma camada anterior a ele conectados, produzindo como saída um valor, resultante de sua função de ativação, que é propagado às camadas seguintes da rede neural. Conforme exemplificado na Figura 3, a combinação das atuações individuais desempenhadas por cada neurônio da rede que define a atuação associada à RNA como um todo (BRAGA; CARVALHO; LUDERMIR, 2007; FACELI et al., 2011; HAYKIN, 2009).

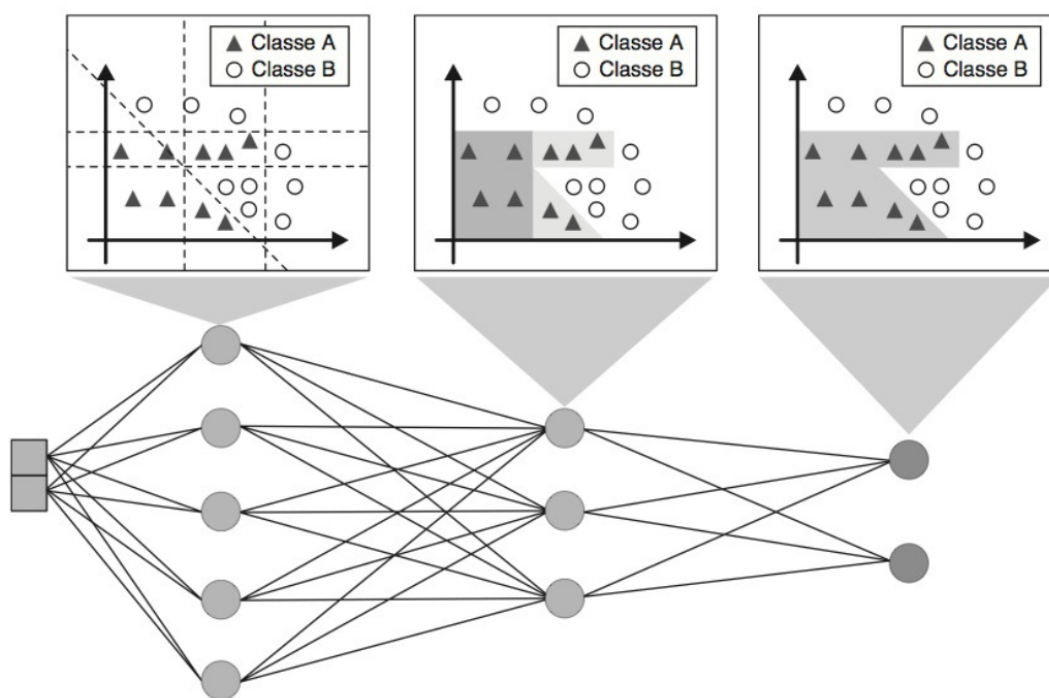


Figura 3: Papel desempenhado pelos neurônios das diferentes camadas de uma rede MLP. Fonte: (FACELI et al., 2011).

Uma importante característica das RNAs é a sua capacidade de aprender por meio de exemplos. O processo de *aprendizado* de uma rede neural consiste em sucessivos ajustes de pesos associados aos seus neurônios, de modo a aprimorar seu desempenho de acordo com um critério pré-estabelecido. Tais ajustes são realizados por algoritmos de treinamento formados por um conjunto de regras bem definidas que especificam quando e como deve ser alterado o valor de cada peso. Diversos algoritmos de aprendizado foram propostos, dentre os quais se destacam aqueles que seguem o paradigma de *aprendizado supervisionado* (FACELI et al., 2011; LIMA, 2016).

O aprendizado supervisionado ajusta os pesos aplicando um conjunto de exemplos de treinamento rotulados. Cada exemplo consiste em um sinal de entrada associado à sua resposta alvo desejada. A cada padrão de entrada submetido à rede, compara-se a resposta desejada com a resposta calculada, ajustando-se os pesos das conexões para minimizar o erro (HAYKIN, 2009).

O algoritmo mais utilizado para o treinamento de redes MLP é o algoritmo *back-propagation*, também chamado de retropropagação do erro ou ainda regra delta generalizada. Este algoritmo respeita o aprendizado supervisionado em que os pesos são modificados e ajustados para reduzir a distância entre a resposta desejada e a resposta produzida pela rede (HAYKIN, 2009). O treinamento é constituído da iteração de duas fases, uma fase para frente (*forward*) e uma fase para trás (*backwards*) (FACELI et al., 2011). A fase *forward*, que compreende o fluxo da informação a partir da entrada até a saída da rede, é utilizada para produzir uma saída para um dado sinal de entrada. A fase *backwards*, com fluxo da informação da saída da rede em direção à entrada, utiliza a diferença entre as saídas desejada e produzida para atualizar os pesos das conexões entre os neurônios e assim minimizar o erro (BRAGA; CARVALHO; LUDERMIR, 2007). Os ciclos de apresentação dos dados de treinamento e eventuais ajustes de pesos no *backpropagation* são iterados até que seja atingido um critério de parada como, por exemplo, um número máximo de ciclos ou uma taxa máxima de erro (FACELI et al., 2011).

As RNAs são modelos computacionais com ampla aplicação na resolução de problemas de previsão. Algumas aplicações utilizam RNAs para predição de condições climáticas, como em (SOUSA et al., 2017) e (ARAUJO et al., 2017), em que se deseja prever precipitações de chuva de determinados locais. Diversas outras aplicações de RNAs dizem respeito à classificação de padrões. Dentre as aplicações na área de classificação financeira, uma das mais bem sucedidas é a análise de crédito (BRAGA; CARVALHO; LUDERMIR, 2007). Além disso, as RNAs também são muito utilizadas para diagnósticos médicos, como em (SILVA et al., 2016) e (PEREIRA et al., 2016). Outras aplicações tratam de reconhecimento de caracteres (CARVALHO, 2006), robótica (TINOS, 1999), jogos (CAEXETA, 2008), comunicação (SILVA et al., 2017), dentre outros.

2.2. Deep Learning

O aprendizado profundo ou *deep learning* é um modelo matemático de aprendizagem de máquina que utiliza RNAs para aprender representações a partir de dados (CHOLLET, 2017; BUDUMA, 2017). Informalmente, a palavra *profundo* se refere à grande quantidade de camadas e neurônios presentes nas arquiteturas das redes (GULLI; PAL, 2017). Através de análise de padrões, os sistemas baseados em técnicas de *deep learning* são capazes de reconhecer, traduzir, sintetizar e até prever sinais das mais diferentes naturezas (DELICATO; PIRES; SILVEIRA, 2017).

2.3. Redes Neurais Convolucionais

As *Redes Neurais Convolucionais*, do inglês *Convolutional Neural Networks* (CNNs), são modelos de redes neurais especializados em processamento de dados compostos pela união de vários segmentos elementares denominados camadas (GOODFELLOW; BENGIO; COURVILLE, 2016). Cada camada possui uma finalidade específica e implementa

uma determinada funcionalidade básica, como convolução, normalização, *pooling*, etc (KHAN et al., 2018).

2.3.1. Convolução

A *convolução* é uma operação linear que calcula a soma dos produtos de toda a extensão de duas entradas em função de um determinado deslocamento. Essa operação é a propriedade fundamental da camada convolucional, a principal camada de uma CNN (GOODFELLOW; BENGIO; COURVILLE, 2016). O principal objetivo da operação de convolução nas CNN é a extração das características de uma determinada entrada (SEWAK; KARIM; PUJARI, 2018).

O processo de convolução utilizado nas CNNs é aplicado em um conjunto de *filtros* e uma dada entrada para gerar uma saída conhecida como *mapa de características*. A camada convolucional recebe um volume de entrada de n dimensões e pode possuir um preenchimento p de zeros (*zero-padding*), aplicado ao redor da entrada. Essa entrada é processada por k filtros que representam os pesos e as conexões da CNN (KHAN et al., 2018). Cada filtro consiste em uma matriz de números discretos e possui uma extensão espacial e , que é igual ao valor da altura e da largura do filtro, e um *stride* s , que é a distância entre as aplicações de convolução consecutivas do filtro no volume de entrada (BUDUMA, 2017).

A Figura 4 exemplifica o processo de convolução aplicado em uma entrada de tamanho 5×5 e *zero-padding* $p = 1$. O filtro utilizado no exemplo possui extensão espacial $e = 2$ e *stride* $s = 2$ com inicialização de pesos aleatória. É possível observar que o mapa de características é uma saída de tamanho 3×3 em que cada um dos seus componentes é a da soma das multiplicações dos elementos do filtro com os elementos de um segmento da entrada (KHAN et al., 2018).




Figura 4: Exemplo de um processo de convolução aplicado em uma entrada de tamanho 5×5 e um filtro de tamanho 2×2 . Fonte: (KHAN et al., 2018).

2.3.2. Camadas de uma CNN

Para reduzir significativamente a dimensão dos mapas de características, eventualmente, após a camada convolucional, é utilizada uma camada chamada *pooling*. A camada de *pooling* divide o mapa de características de entrada em blocos de tamanhos iguais e processa cada bloco para criar um mapa de características condensado. O processamento dos blocos é definido por uma função de *pool* que pode ser, por exemplo, a função máxima. Assim como na camada de convolução, na camada de *pooling* também é preciso especificar o tamanho da região de *pooling* e o *stride* s da operação, conforme exemplificado na Figura 5 em que a região possui tamanho 2×2 e o *stride* $s = 1$ (BUDUMA, 2017; KHAN et al., 2018).




Figura 5: Exemplo de um processo de *pooling* aplicado em uma entrada de tamanho 5×5 e uma região *pooling* de tamanho 2×2 . Fonte: (KHAN et al., 2018).

2.4. Tecnologias Utilizadas

3. Trabalhos Relacionados

4. Solução Proposta

4.1. Visão Geral da solução proposta

4.2. Análise Comparativa

5. Considerações Parciais

Referências

ARAÚJO, N. et al. Previsão do volume mensal de precipitações em manaus, amazonas com redes neurais artificiais. In: *Anais do IV Encontro Regional de Informática da Região Norte I*. Manaus, Amazonas: ERIN, 2017. p. 108–116.

BRAGA, A. de P.; CARVALHO, A. P. de Leon F. de; LUDERMIR, T. B. *Redes Neurais Artificiais: Teoria e Aplicações*. 2. ed. Rio de Janeiro, Rio de Janeiro: LTC, 2007.

BUDUMA, N. *Fundamentals of Deep Learning: Designing Next-Generation Machine Intelligence Algorithms*. 1. ed. Sebastopol, California: O'Reilly Media, 2017.

CAEXETA, G. S. *VisionDraughts - Um Sistema de Aprendizagem de Jogos de Damas em Redes Neurais, Diferenças Temporais, Algoritmos Eficientes de Busca em Árvore e Informações Perfeitas Contidas em Bases de Dados*. Uberlândia, Minas Gerais: [s.n.], 2008.

CARVALHO, C. E. S. de. *Reconhecimento de Caracteres Manuscritos Utilizando Redes Neurais Artificiais*. Brasília, Distrito Federal: [s.n.], 2006.

CHOLLET, F. *Deep Learning with Python*. 1. ed. Shelter Island, New York: Manning, 2017.

CYBENKO, G. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals, and Systems*, v. 2, p. 303–314, December 1989.

DELICATO, F.; PIRES, P.; SILVEIRA, I. Jornada de atualização em informática 2017. In: _____. 1. ed. Porto Alegre, Rio Grande do Sul: SBC, 2017. (1, v. 1), cap. 6, p. 212–260.

FACELI, K. et al. *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. 1. ed. Rio de Janeiro, Rio de Janeiro: LTC, 2011.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. 1. ed. Cambridge, Massachusetts: The MIT Press, 2016. v. 1. (Adaptive computation and machine learning series, v. 1).

GULLI, A.; PAL, S. *Deep Learning with Keras*. 1. ed. Birmingham, West Midlands: Packt, 2017.

HAYKIN, S. S. *Neural Networks and Learning Machines*. 3. ed. Upper Saddle River, New Jersey: Perason, 2009.

KHAN, S. et al. *A Guide to Convolutional Neural Networks for Computer Vision*. 1. ed. [S.l.]: Morgan and Claypool, 2018. v. 1. (Synthesis Lectures on Computer Vision, v. 1).

LIMA, P. M. de. *Redes Neurais para Predição de Séries Temporais de Precipitação em Manaus, Amazonas*. 2016. Trabalho de Conclusão de Curso da Universidade do Estado do Amazonas. Universidade do Estado do Amazonas.

PEREIRA, R. et al. Abordagem deep learning para classificação de lesões mamárias. In: *Anais do XXXVI Congresso da Sociedade Brasileira de Computação*. Porto Alegre, Rio Grande do Sul: CSBC, 2016. p. 2597–2600.

ROJAS, R. *Neural Networks: A Systematic Introduction*. 1. ed. Heidelberg, Berlin: Springer, 1996.

ROSENBLAT, F. *Principles of Neurodynamics: Perceptrons and the theory of brain mechanisms*. Washington, DC, 1961. 626 p.

SEWAK, M.; KARIM, R.; PUJARI, P. *Practical Convolutional Neural Networks*. 1. ed. Birmingham, West Midlands: Packt, 2018.

SILVA, A. G. et al. Classificação de expressões faciais negativas na língua brasileira de sinais. In: *Anais do IV Encontro Regional de Informática da Região Norte I*. Manaus, Amazonas: ERIN, 2017. p. 80–88.

SILVA, G. da et al. Classification of malignancy of lung nodules in ct images using convolutional neural network. In: *Anais do XXXVI Congresso da Sociedade Brasileira de Computação*. Porto Alegre, Rio Grande do Sul: CSBC, 2016. p. 2481–2489.

SOUSA, R. et al. Redes neurais artificiais aplicadas à previsão antecipada de precipitações na região central de manaus. In: *Anais do IV Encontro Regional de Informática da Região Norte I*. Manaus, Amazonas: ERIN, 2017. p. 89–97.

TINOS, R. *Detecção e Diagnóstico de Falhas em Robôs Manipuladores via Redes Neurais Artificiais*. São Carlos, São Paulo: [s.n.], 1999.